DANH SÁCH HOẠT ĐỘNG CHI TIẾT ĐỂ CÁC NHÓM FOLLOW

Ngày tổng kết Phase 1 – từ recap đến mini project nhóm

> **Mục tiêu của tài liệu** Tài liệu này mô tả **nhóm cần làm gì theo từng khung giờ**, đầu ra cần nộp ở mỗi hoạt động, và checklist để không bị lệch mục tiêu trong ngày.

---

1. Mục tiêu cuối ngày của mỗi nhóm

Đến cuối ngày, mỗi nhóm cần hoàn thành:

1. Một bộ **worksheet buổi sáng**;
2. Một **mini project proposal** dạng 5-7 slide hoặc 1 poster/1-page proposal;
3. Một kết luận rõ ràng về **deployment, cost, reliability và định hướng Track Phase 2**;
4. Các phiếu chấm peer review cho những đội còn lại trong zone.

---

2. Checklist chuẩn bị đầu ngày

- [ ] Nhóm đã có đủ thành viên 4-6 người.
- [ ] Nhóm đã chọn chủ đề hoặc scenario card.
- [ ] Nhóm đã cử các vai trò chính: Product lead, Architect, Cost lead, Reliability lead, Presenter.
- [ ] Nhóm đã có nơi ghi chép chung (giấy A3 hoặc file chung).

---

3. Buổi sáng – hoạt động và đầu ra

3.1. 08:00 – 08:15 | Khởi động và mini reflection

Nhóm cần làm gì?

- Mỗi người viết nhanh 3 ý: điều học được nhiều nhất, điểm yếu nhất, hướng muốn đi sâu;
- Cử một người tổng hợp để nhóm nhìn thấy điểm mạnh/điểm yếu chung.

Đầu ra cần có:

- 3-5 ý tổng hợp của nhóm về hiện trạng năng lực.
    - **Điểm mạnh:** Làm chủ Local LLM (Ollama, Qwen 3.5), kinh nghiệm thực chiến về RAG và Agentic Workflow (LangGraph).
    - **Điểm yếu:** Kinh nghiệm về Cloud Infrastructure và Deployment ở quy mô Enterprise (triệu user) còn hạn chế.
    - **Hướng muốn đi sâu:** Tối ưu hóa hiệu suất Real-time Multi-modal (kết hợp CV + Voice + LLM).

3.2. 08:15 – 08:40 | Hoạt động 1 – Learning Timeline

Mục tiêu: xác định nhóm đã build được gì trong 15 ngày và chọn đúng dự án để phân tích production.

Nhóm cần làm gì?

1. Liệt kê 2-3 kỹ năng nhóm tự tin nhất;

   - **Kỹ năng tự tin nhất:** Xây dựng Multi-agent system, Xử lý Computer Vision (Eye tracking), Optimization (Quantization).

2. Mô tả ngắn sản phẩm/agent nhóm đã làm hoặc scenario được chọn;

   - **Mô tả sản phẩm:** Hệ sinh thái Trợ lý ảo Học tập Đa phương thức giúp giám sát tập trung, ghi chú rảnh tay và quản lý lịch trình thông minh.

3. Chốt 1 chủ đề sẽ theo xuyên suốt cả ngày.

   - Chủ đề: Trợ lý học tập đa phương thức (Multimodal AI Agent) hoạt động trên thiết bị local

Câu hỏi nhóm phải trả lời:

- Sản phẩm này giải quyết bài toán gì?

  - Giải quyết bài toán xao nhãng và thiếu động lực của học sinh/sinh viên bằng một trợ lý ảo có khả năng tương tác hai chiều tự nhiên (Nhìn - Nghe - Hiểu).

- Ai là người dùng chính?

  - Sinh viên/Nghiên cứu viên cần tập trung cao độ.

- Vì sao chủ đề này phù hợp để phân tích deployment và cost?

  - Phức tạp về mặt tích hợp phần cứng (Vision + Voice + LLM), rất phù hợp để phân tích bài toán chi phí compute (GPU local) và độ trễ (latency).

Đầu ra: Worksheet 0.

3.3. 08:40 – 09:25 | Hoạt động 2 – Enterprise Deployment Clinic

Mục tiêu: hiểu vì sao deploy demo và deploy enterprise là hai bài toán khác nhau.

Nhóm cần làm gì?

1. Xác định bối cảnh tổ chức/khách hàng sử dụng hệ thống;

   - **Bối cảnh:** Triển khai dưới dạng một ứng dụng Personal Productivity Tool.

2. Liệt kê dữ liệu mà hệ thống sẽ động đến;

   - **Dữ liệu:** Luồng video webcam, âm thanh ghi âm, lịch trình cá nhân, ghi chú kiến thức (Notion).

3. Đánh giá mức độ nhạy cảm của dữ liệu;

   - **Mức độ nhạy cảm: Rất cao** (Dữ liệu hình ảnh và giọng nói cá nhân).

4. Liệt kê 3 ràng buộc enterprise lớn nhất;

   - **3 Ràng buộc lớn:** Privacy (không upload video lên cloud), Latency (nhắc nhở phải real-time), Local Compute (phụ thuộc GPU người dùng).

5. Chọn Cloud, On-prem hoặc Hybrid;

   - **Mô hình chọn: Hybrid** (Local Inference cho CV/STT/LLM để bảo mật; Cloud cho việc đồng bộ dữ liệu lên Notion/Calendar).

6. Viết 2 lý do vì sao chọn mô hình đó.

   - **Lý do:** Tối ưu bảo mật dữ liệu nhạy cảm và giảm chi phí API liên tục.

Gợi ý thảo luận:

- Có cần audit trail không?
- Dữ liệu có được rời khỏi tổ chức không?
- Có cần tích hợp hệ thống cũ hoặc quy trình phê duyệt không?
- Nếu trả lời sai thì ai bị ảnh hưởng đầu tiên?

Đầu ra: Worksheet 1.

3.4. 09:25 – 10:15 | Hoạt động 3 – Cost Analysis

Mục tiêu: bóc tách cost của AI system thay vì chỉ nhìn vào token/API.

Nhóm cần làm gì?

- Ước lượng số user/ngày, request/ngày, peak traffic;

  - **Thông số giả định:** ước lượng 500 user (tùy giai đoạn), 20 - 30 request LLM/ngày/user, webcam chạy 4h/ngày.

- Ước lượng input/output tokens nếu dùng LLM API;

  - Giả định 1 user học 2 tiếng/ngày, sử dụng hệ thống ghi chú 5 lần, hỏi đáp 2 lần và hệ thống chạy nền để phân tích mức độ tập trung.

  - **Input Tokens (Prompt + Context + STT text):**
    - Mỗi lần ghi chú/hỏi đáp: ~300 tokens x 7 lần = 2,100 tokens.
    - Phân tích dữ liệu tập trung cuối buổi: ~900 tokens.
    - **Tổng Input/User/Ngày:** ~3,000 tokens.
  - **Output Tokens (LLM Refined Note + Text trả lời để đưa vào TTS):**
    - Mỗi lần ghi chú (đã được làm gọn): ~100 tokens x 7 = 700 tokens.
    - Nhận xét/Gợi ý từ dữ liệu tập trung: ~300 tokens.
    - **Tổng Output/User/Ngày:** ~1,000 tokens.

  - *Tóm lại:* Một user tiêu tốn khoảng **90,000 Input Tokens** và **30,000 Output Tokens** mỗi tháng.

- Liệt kê các lớp cost: token, compute, storage, human review, logging, maintenance;

  - Nếu không chạy trên máy tính cá nhân của user mà đưa hệ thống lên dạng SaaS (Software as a Service), chi phí sẽ chia thành các lớp sau:

    - **Token Cost:** Trả cho nhà cung cấp LLM (ví dụ: OpenAI GPT-4o-mini hoặc Claude 3 Haiku) dựa trên lượng input/output token ở trên. (Nếu dùng thêm Whisper API cho STT hoặc Eleven Labs cho TTS thì phí này sẽ đội lên).
    - **Compute (Máy chủ xử lý):** Tiền thuê server ảo (VPS/EC2) để chạy backend (Fast API/Nodejs) làm nhiệm vụ nhận request từ app, gọi LLM API và trả kết quả về.
    - **Storage (Lưu trữ Database):** Tiền thuê cơ sở dữ liệu (như PostgreSQL hoặc MongoDB) để lưu trữ 3 trang Dashboard (Lịch học, Ghi chú, Lịch sử tập trung).
    - **Logging:** Chi phí cho các dịch vụ theo dõi lỗi và lưu log hệ thống (ví dụ: Datadog, AWS CloudWatch) để biết lúc nào API bị timeout hoặc rớt mạng.
    - **Human Review (Đánh giá thủ công):** Thời gian và nhân sự (có thể là các bạn trong nhóm) ngồi đọc lại các logs ghi chú của hệ thống trong giai đoạn đầu để tinh chỉnh Prompt sao cho LLM tóm tắt hay hơn.
    - **Maintenance:** Công sức bảo trì, fix bug, và nâng cấp version của các thư viện CPV, STT.
- Tính sơ bộ cost ở mức MVP;

  Giả định MVP có 50 users tích cực dùng hàng ngày (Chạy 100% Local trên máy trạm RTX 4090).

- ***Chi phí Token / Bản quyền AI:*** *Sử dụng các mô hình mã nguồn mở: Qwen 3.5 / Llama 3 (LLM), Faster-Whisper (STT), và Piper (TTS). Toàn bộ chạy offline trên 24GB VRAM.*
    - => ***$0/tháng.***
- ***Chi phí Compute (Vận hành & Khấu hao):*** ** Tiền điện: Máy chủ bật 24/7 (trong đó 8-10 tiếng tải nặng phục vụ 50 users, còn lại chạy không tải). Mức tiêu thụ ước tính 150 - 200 kWh/tháng. =>* ***~$20 - $25/tháng*** *(Khoảng 500.000đ - 600.000đ).*
- ***Chi phí Storage & Database:*** ** Cài đặt trực tiếp SQLite hoặc PostgreSQL trên ổ cứng SSD của máy chủ Local để lưu trữ 3 trang Dashboard.*
    - => ***$0/tháng.***
- ***Chi phí Domain / Network:*** ** Mua tên miền riêng và sử dụng dịch vụ như Cloudflare Tunnel (miễn phí) hoặc Ngrok để mở cổng (expose) an toàn cho 50 users truy cập từ xa vào máy Local mà không cần thuê IP tĩnh hay lộ mạn lưới nội bộ.*
    - => ***~$5/tháng.***

=> ***Tổng chi phí vận hành MVP (Thực chi tiền mặt):*** *Khoảng* ***$25 - $30/tháng****.*

- Suy nghĩ xem khi số user tăng 5x hoặc 10x thì phần nào tăng mạnh nhất.

  Phần tăng mạnh nhất và nguy hiểm nhất là Compute (Backend) và Database Connections. * Khi có 500 users (10x), lượng kết nối đồng thời (Concurrent connections) đẩy dữ liệu Eye-tracking liên tục về server sẽ làm **nghẽn cổ chai (Bottleneck)**. Server giá $15/tháng sẽ sập ngay lập tức.

Câu hỏi nhóm phải trả lời:

- Cost driver lớn nhất của hệ thống là gì?

  - **Cost driver lớn nhất:** Điện năng và Khấu hao GPU khi chạy Inference Vision liên tục.

- Hidden cost nào dễ bị quên nhất?

  - Hidden cost: Chi phí lưu trữ Database cho bảng thống kê mức độ tập trung theo thời gian.

- Đội có chỗ nào đang ước lượng quá lạc quan không?

  - Ước lượng lạc quan: Giả định người dùng nào cũng có GPU mạnh. Thực tế cần tính thêm chi phí server nếu user dùng máy yếu.

Đầu ra: Worksheet 2.

3.5. 10:15 – 10:50 | Hoạt động 4 – Cost Optimization Debate

Mục tiêu: chọn đúng chiến lược tối ưu thay vì tối ưu theo phong trào.

Nhóm cần làm gì?

1. Chọn 3 chiến lược optimization phù hợp nhất;
2. Với mỗi chiến lược, viết rõ tiết kiệm phần nào, lợi ích, trade-off và thời điểm áp dụng;
3. Chốt chiến lược nào làm ngay, chiến lược nào để sau.

Các chiến lược thường gặp:

- Model routing;
- Semantic caching;
- Prompt compression;
- Smaller/self-hosted model khi volume đủ lớn;
- Selective inference hoặc phân tầng user/request.

3 Chiến lược chọn:

1. **Selective Inference:** Chỉ bật STT khi có tín hiệu VAD (Voice Activity Detection), không chạy STT liên tục.
2. **Model Quantization (4-bit/8-bit):** Dùng cho Model STT, TTS để tiết kiệm VRAM cho module Vision.
3. **Frame Skipping:** CPV chỉ phân tích 5-10 frame/giây thay vì 30-60 frame để giảm tải GPU.

Chiến lược làm ngay: VAD và Quantization.

Đầu ra: Worksheet 3.

3.6. 10:50 – 11:25 | Hoạt động 5 – Scaling & Reliability Tabletop

Mục tiêu: luyện phản ứng khi hệ thống gặp tải tăng hoặc provider lỗi.

Nhóm cần làm gì?

1. Xem xét 3 tình huống: traffic tăng đột biến, provider timeout, response chậm;
2. Với mỗi tình huống, mô tả tác động tới user;
3. Ghi phản ứng ngắn hạn và giải pháp dài hạn;
4. Chọn các metric cần monitor;
5. Viết fallback proposal.

Gợi ý:

- Request nào cần real-time, request nào có thể async?
- Có cần queue, circuit breaker hay retry policy không?
- Fallback nên là model khác, rule-based flow hay human escalation?

Tình huống	Tác động	Phản ứng ngắn hạn	Giải pháp dài hạn
GPU OOM (Tràn RAM)	Crash ứng dụng	Restart service, hạ Quantization	Triển khai load balancing giữa các GPU (nếu có cụm cluster)
Notion API Down	Không lưu được note	Lưu tạm vào SQLite Local	Cơ chế Retry và Sync khi có mạng lại
Webcam lỗi	Mất tính năng giám sát	TTS thông báo lỗi cho user	Dùng các metric khác (tốc độ gõ phím) làm fallback

- Metric cần monitor: GPU Usage, Inference Latency, STT Accuracy Rate.

- Fallback: Nếu LLM local quá tải, chuyển sang dùng API nhỏ (như Groq) để xử lý nhanh các tác vụ đơn giản.

Đầu ra: Worksheet 4.

3.7. 11:25 – 11:45 | Hoạt động 6 – Skills Map & Track Direction

Mục tiêu: kết nối dự án với năng lực hiện tại và hướng đi Phase 2.

Nhóm cần làm gì?

1. Mỗi thành viên tự chấm 1-5 ở ba mảng: Business/Product, Infra/Data/Ops, AI Engineering/Application;
2. Cả nhóm thảo luận xem điểm mạnh nằm ở đâu;
3. Chọn Track Phase 2 phù hợp nhất;
4. Ghi 2-3 kỹ năng cần bù nếu muốn tiếp tục dự án này.

Skills Map:

- Business/Product: 3/5
- Infra/Data/Ops: 3.5/5
- **AI Engineering/Application: 4.5/5**

Điểm mạnh: Hiện thực hóa ý tưởng AI thành sản phẩm chạy được (Application).

Track Phase 2: AI Engineering Track (Tập trung tối ưu Agentic Workflow và Multimodal Interaction).

Kỹ năng cần bù: Kỹ năng về Cloud Orchestration (Kubernetes) nếu muốn scale dự án lên quy mô lớn hơn.

Đầu ra: Worksheet 5.

---

4. Buổi chiều – làm mini project và thuyết trình theo zone

4.1. 13:30 – 13:45 | Chia zone và chốt vai trò

Checklist:

- [ ] Đã biết zone của nhóm.
- [ ] Đã có presenter và người trả lời Q&A.
- [ ] Đã thống nhất format nộp bài: slide hoặc poster.

4.2. 14:00 – 15:10 | Sprint 1 – Xây nội dung proposal

Nhóm cần hoàn thành 7 khối nội dung:

1. Project overview;
2. Enterprise context;
3. Deployment choice;
4. Cost analysis (MVP + Growth);
5. Optimization plan;
6. Reliability plan;
7. Track recommendation + next step.

4.3. 15:20 – 16:00 | Sprint 2 – Đóng gói thành bản trình bày

Cấu trúc slide đề xuất:

1. Tên dự án, user, bài toán
2. Bối cảnh enterprise và ràng buộc
3. Kiến trúc triển khai đề xuất
4. Cost anatomy
5. Cost optimization
6. Reliability & scaling
7. Track đề xuất và bước đi tiếp theo

4.4. 16:10 – 17:20 | Zone presentation + peer review

Format cho mỗi đội:

- 5 phút trình bày;
- 3 phút Q&A/phản biện;
- 2 phút các đội khác chấm phiếu.

Luật bắt buộc:

- Đội không tự chấm mình;
- Mỗi đội phải đặt ít nhất 1 câu hỏi thật cho ít nhất 2 đội khác;
- Phản biện phải có: 1 điểm mạnh, 1 điểm cần cải thiện, 1 đề xuất thay thế.

---

5. Checklist nộp cuối ngày

- [ ] Worksheet 0-5 của nhóm
- [ ] Slide hoặc poster mini project
- [ ] Phiếu chấm cho các đội khác trong zone
- [ ] Kết luận Track Phase 2 của nhóm

---

6. Mẫu trang ghi chú nhanh của nhóm

Team note sheet

- Tên nhóm: Nhóm 24 (Team 24)
- Chủ đề: Trợ lý học tập đa phương thức (Multimodal AI Agent) hoạt động trên thiết bị local
- 3 ràng buộc enterprise lớn nhất: Privacy (bảo mật dữ liệu, không upload video lên cloud), Latency (yêu cầu độ trễ thấp để nhắc nhở real-time), và Local Compute (phụ thuộc vào cấu hình GPU của người dùng)

- Cost driver lớn nhất: Điện năng và sự khấu hao GPU khi phải chạy Inference Vision liên tục
- 3 chiến lược optimize được chọn:
    - Selective Inference: Chỉ bật tính năng STT (Speech-to-Text) khi nhận diện có tín hiệu VAD (Voice Activity Detection), tránh chạy liên tục.
    - Model Quantization (4-bit/8-bit): Áp dụng cho các mô hình STT và TTS nhằm tiết kiệm dung lượng VRAM cho module Vision.
    - Frame Skipping: Chỉ phân tích từ 5-10 frame/giây thay vì mức thông thường 30-60 frame/giây để giảm tải cho GPU
- Fallback / reliability plan ngắn gọn:
    - Khi tràn RAM (GPU OOM): Khởi động lại service, hạ mức độ Quantization xuống, hoặc sử dụng load balancing nếu có hệ thống cụm máy chủ
    - Khi Notion API sập: Lưu dữ liệu tạm thời vào SQLite Local, tự động retry và đồng bộ hóa (sync) khi kết nối mạng ổn định lại
    - Khi lỗi Webcam: Hệ thống sẽ dùng TTS thông báo lỗi cho người dùng và chuyển sang dùng các metric thay thế (như tốc độ gõ phím)
- Khi LLM local quá tải: Tự động chuyển qua sử dụng các API nhỏ và nhẹ hơn (như Groq) để xử lý nhanh các tác vụ đơn giản
- Track Phase 2 đề xuất: AI Engineering Track, với mục tiêu tập trung vào việc tối ưu hóa Agentic Workflow và Multimodal Interaction (Tương tác Đa phương thức)